Ciencia de Datos
Políticas Públicas

SEMANA 1

Introducción — qué es la ciencia de datos y por qué importa en políticas públicas

Diana Mendez · TC4036 · Tecnológico de Monterrey

¿Qué vamos a ver hoy?

1. ¿Qué es una política pública? — definición y ejemplos
2. ¿Qué es la ciencia de datos?
3. ¿Por qué combinarlos? — sin datos vs. con datos
4. Ejemplos concretos: John Snow, CONEVAL, cambio climático
5. Correlación ≠ causalidad — distinción crítica en política
6. Herramientas, estructura del curso y proyecto final

¿Qué es una política pública?

¿Qué es una política pública?

Decisiones tomadas por gobiernos para resolver problemas públicos

Cambio climático

Salud pública

Educación

Transporte

¿Qué es una política pública?

Decisiones tomadas por gobiernos para resolver problemas públicos

Cambio climático

Impuestos al carbono, subsidios a renovables, reforestación

Salud pública

Cobertura médica, vacunación, hospitales rurales

Educación

Becas, infraestructura escolar, calidad docente

Transporte

Metro, ciclovías, transporte eléctrico, movilidad urbana

Ejemplos de preguntas de política

🏥 ¿Qué regiones necesitan más hospitales?

💰 ¿Un subsidio reduce la pobreza en municipios rurales?

☀️ ¿Dónde instalar paneles solares para mayor impacto?

🌡️ ¿Cómo afecta la temperatura a la mortalidad infantil?

💬 Pausa — pregunta a los estudiantes: ¿qué problema les gustaría resolver con datos?

¿Qué es la ciencia de datos?

- ” Es el proceso de usar los datos para entender el mundo.”
- “Es un campo de procedimientos y sistemas para extraer datos en varios formatos, ya sea ordenados o desordenados.”
- “Es el estudio de los datos. Asi como ciencias biologicas estudia la biologia, o las ciencias fisicas estudian la fisica.”
- “La Ciencia de datos es un intento de trabajar con datos para encontrar respuestas a las preguntas que se estan explorando. En general, es mas acerca de datos que de ciencia. Si tienes datos y curiosidad, y estás trabajando con los datos, explorando, limpiando, manipulando, ese ejercicio de analizarlos e intentar de obtener respuestas es ciencia de datos.”

¿Qué es la ciencia de datos?

Estadística

modelos, incertidumbre, inferencia

Programación

automatización, escala, reproducibilidad

Conocimiento del dominio

contexto, preguntas que valen la pena hacer

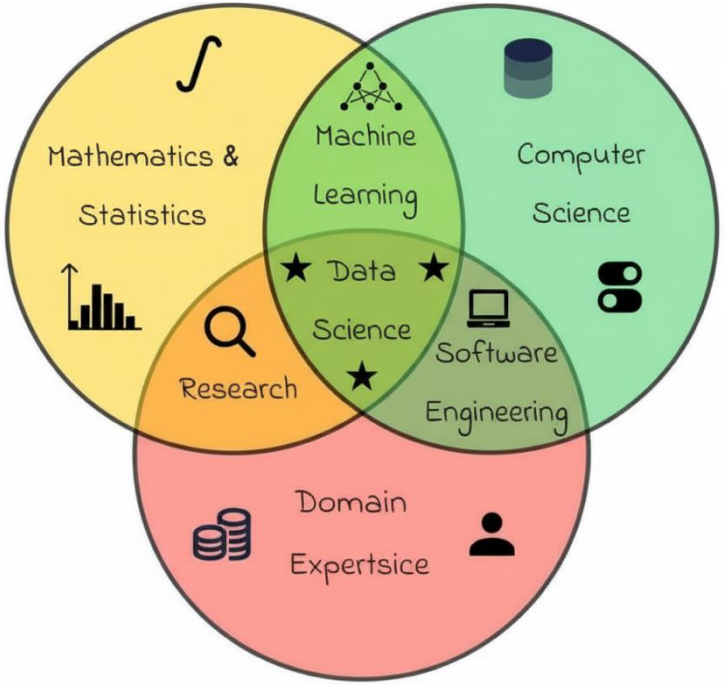

Analisis de datos: patrones historicos y tendencias *¿que pasó?*

Ciencia de datos: extiende patrones para predecir el futuro
¿qué pasará y como influir en futuros patrones?

El ciclo de vida de un proyecto de datos

1 — Recolección

APIs, encuestas, datos abiertos

2 — Limpieza

missing values, formatos, errores

3 — Análisis

estadística, modelos, ML

4 — Visualización

gráficas, dashboards

5 — Comunicación

informes, decisiones

→ En este curso recorreremos este ciclo completo, aplicado a preguntas de política pública.

¿Cuál de estos pasos creen que es el más difícil? ¿El más subestimado?

¿Por qué importa la ciencia de datos en políticas públicas?

Escala

Los gobiernos manejan millones de beneficiarios y registros. Los métodos cuantitativos son la única forma de entenderlos a esa escala.

Evidencia

Las intuiciones no son suficientes. Las políticas basadas en evidencia tienen mejores resultados — y son más difíciles de impugnar.

Transparencia

Cuando el análisis es reproducible y documentado, las decisiones pueden ser auditadas, cuestionadas y mejoradas por otros.

¿Por qué combinar datos y política pública?

Sin datos

- Decisiones basadas en intuición
- Recursos mal distribuidos
- Políticas que no funcionan y nadie sabe por qué
- Difícil rendir cuentas

Con datos

- Decisiones basadas en evidencia
- Recursos dirigidos donde más impactan
- Políticas evaluables y mejorables
- Transparencia y rendición de cuentas

Ejemplo: ¿qué estado debe recibir más recursos de salud?

Pregunta de política: ¿Cómo distribuir el presupuesto federal de salud entre estados?

1

Población

¿Cuántas personas hay que atender?

2

Ingreso promedio

¿Qué capacidad tienen de pagar servicios?

3

Acceso a servicios

¿Cuántos hospitales hay por habitante?

¿Qué otros datos incluirías? ¿Qué datos podrían faltar o estar sesgados?

Ejemplo: ¿qué estado debe recibir más recursos de salud?

Pregunta de política: ¿Cómo distribuir el presupuesto federal de salud entre estados?

- Prevalencia de enfermedades crónicas (diabetes, hipertensión — especialmente relevante en México)
- Mortalidad materna por municipio
- Dispersión geográfica (no es lo mismo tener un hospital en una ciudad que en sierra o selva)

⚠ Los datos de salud tienen sesgos sistemáticos de cobertura — las poblaciones más marginadas suelen estar sub-representadas en los registros administrativos. * Semana 2

Un ejemplo clásico: John Snow y el cólera (Londres, 1854)

La epidemia de cólera de 1854 mató a cientos en el barrio de Soho. La teoría dominante culpaba al "mal aire".

John Snow hizo algo diferente:

- Mapeó cada muerte en el vecindario
- Identificó un cluster alrededor de una bomba de agua
- Persuadió a las autoridades de remover el mango
- La epidemia terminó

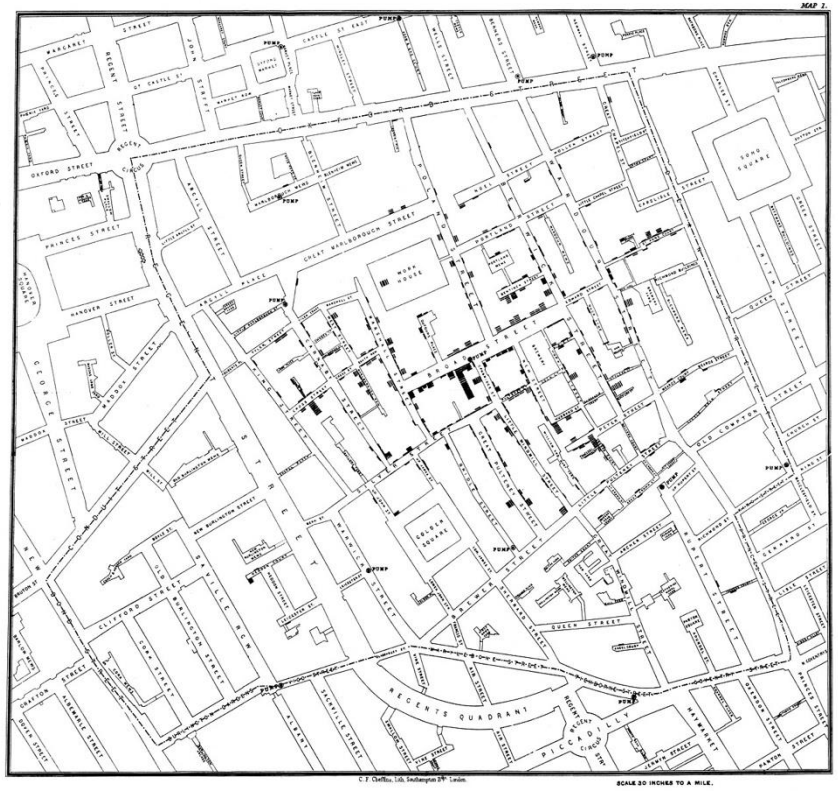

Snow no sabía de bacterias. Sabía de datos, mapas y patrones.

Ejemplo contemporáneo: CONEVAL y la pobreza en México

CONEVAL mide la pobreza multidimensional cada dos años. Sin ciencia de datos, esto sería imposible.

46.8%

de los mexicanos en situación de pobreza
~58.5 millones de personas

8.9%

en pobreza extrema
~11.2 millones de personas

6 dims

de carencia usadas en la medición
educación, salud, Vivienda…

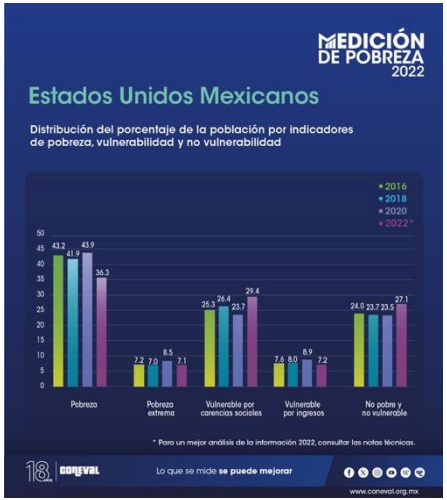

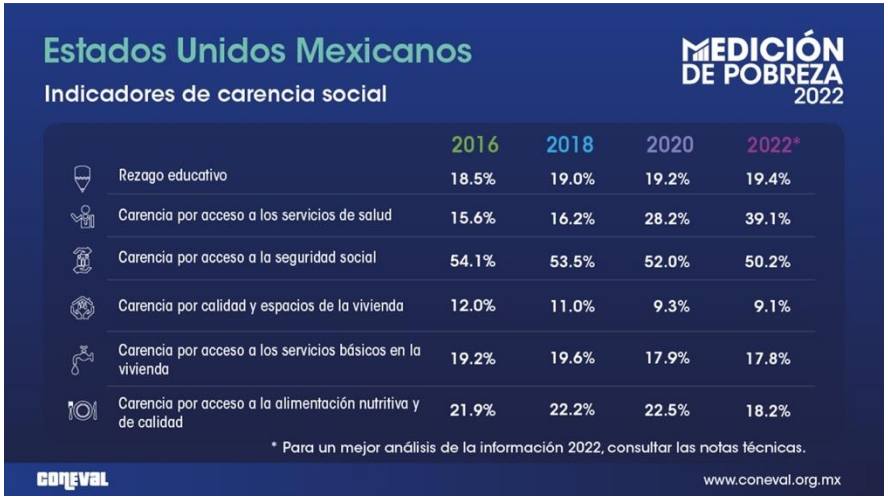

Estados Unidos Mexicanos

MEDICIÓN DE POBREZA 2022

Indicadores de carencia social

	2016	2018	2020	2022*
Rezago educativo	18.5%	19.0%	19.2%	19.4%
Carencia por acceso a los servicios de salud	15.6%	16.2%	28.2%	39.1%
Carencia por acceso a la seguridad social	54.1%	53.5%	52.0%	50.2%
Carencia por calidad y espacios de la vivienda	12.0%	11.0%	9.3%	9.1%
Carencia por acceso a los servicios básicos en la vivienda	19.2%	19.6%	17.9%	17.8%
Carencia por acceso a la alimentación nutritiva y de calidad	21.9%	22.2%	22.5%	18.2%

* Para un mejor análisis de la información 2022, consultar las notas técnicas.

CONEVAL www.coneval.org.mx

Ejemplo contemporáneo: CONEVAL y la pobreza en México

CONEVAL mide la pobreza multidimensional cada dos años. Sin ciencia de datos, esto sería imposible.

46.8%

de los mexicanos en situación de pobreza
~58.5 millones de personas

8.9%

en pobreza extrema
~11.2 millones de personas

6 dims

de carencia usadas en la medición
educación, salud, Vivienda…

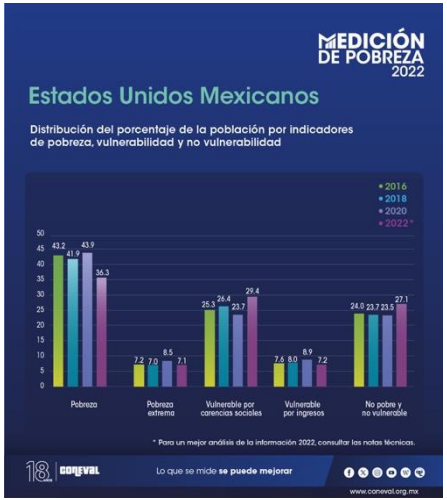

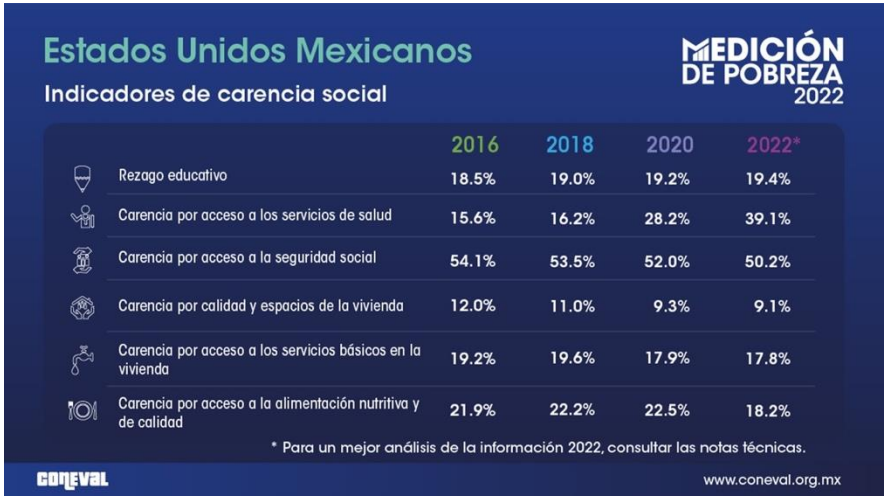

	2016	2018	2020	2022*
Rezago educativo	18.5%	19.0%	19.2%	19.4%
Carencia por acceso a los servicios de salud	15.6%	16.2%	28.2%	39.1%
Carencia por acceso a la seguridad social	54.1%	53.5%	52.0%	50.2%
Carencia por calidad y espacios de la vivienda	12.0%	11.0%	9.3%	9.1%
Carencia por acceso a los servicios básicos en la vivienda	19.2%	19.6%	17.9%	17.8%
Carencia por acceso a la alimentación nutritiva y de calidad	21.9%	22.2%	22.5%	18.2%

→ Focalización de programas sociales (Sembrando Vida, Bienestar)
→ Presupuestp de la Secretaría de Bienestar
→ Priorización de inversion en infraestructura básica

⭐ Semana 9 (ML para clasificación): datos CONEVAL para clasificación municipal

Tercer ejemplo: el cambio climático como problema de datos

Sabemos que el clima está cambiando porque tenemos datos — décadas de mediciones, satélites y estaciones. Sin ciencia de datos, la política climática operaría a ciegas.

422 ppm

concentración de CO_2 en la atmósfera
vs. ~280 ppm pre-industrial

36.8 Gt

emisiones anuales de CO_2 (2023)
equivalente: 100 M trasatlánticos/día

+1.3°C

anomalía de temperatura global (2023)
sobre nivel pre-industrial

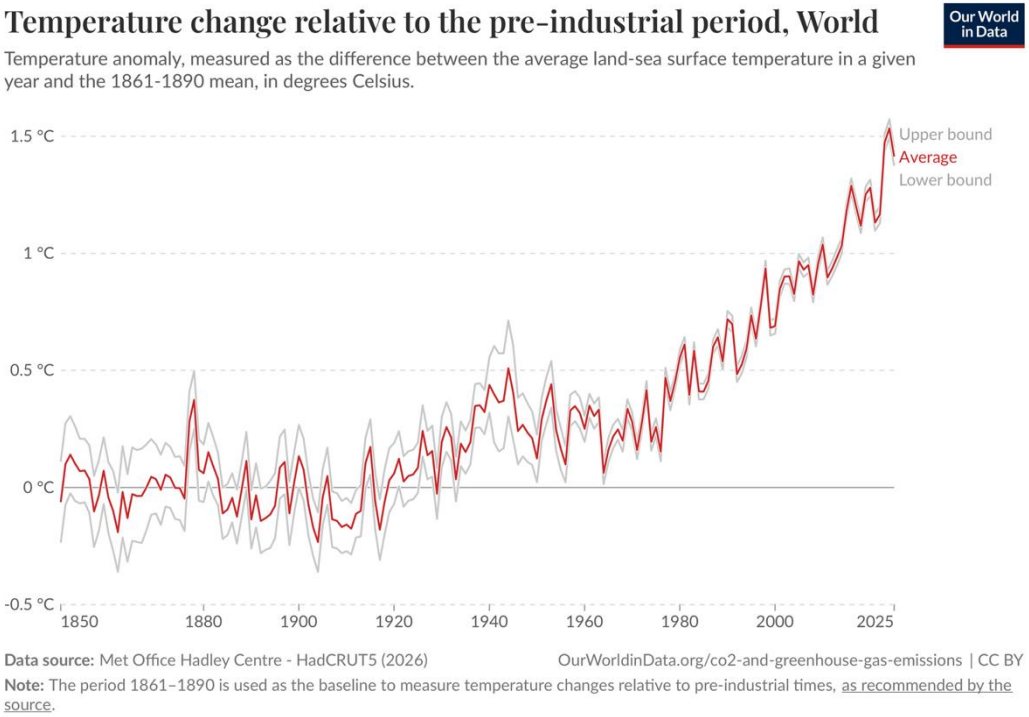

¿Qué tipos de preguntas puede responder la ciencia de datos?

Descriptivo

¿Qué está pasando?

¿Qué porcentaje de la población tiene acceso a combustibles limpios para cocinar?

tablas, visualizaciones, estadísticas de resumen

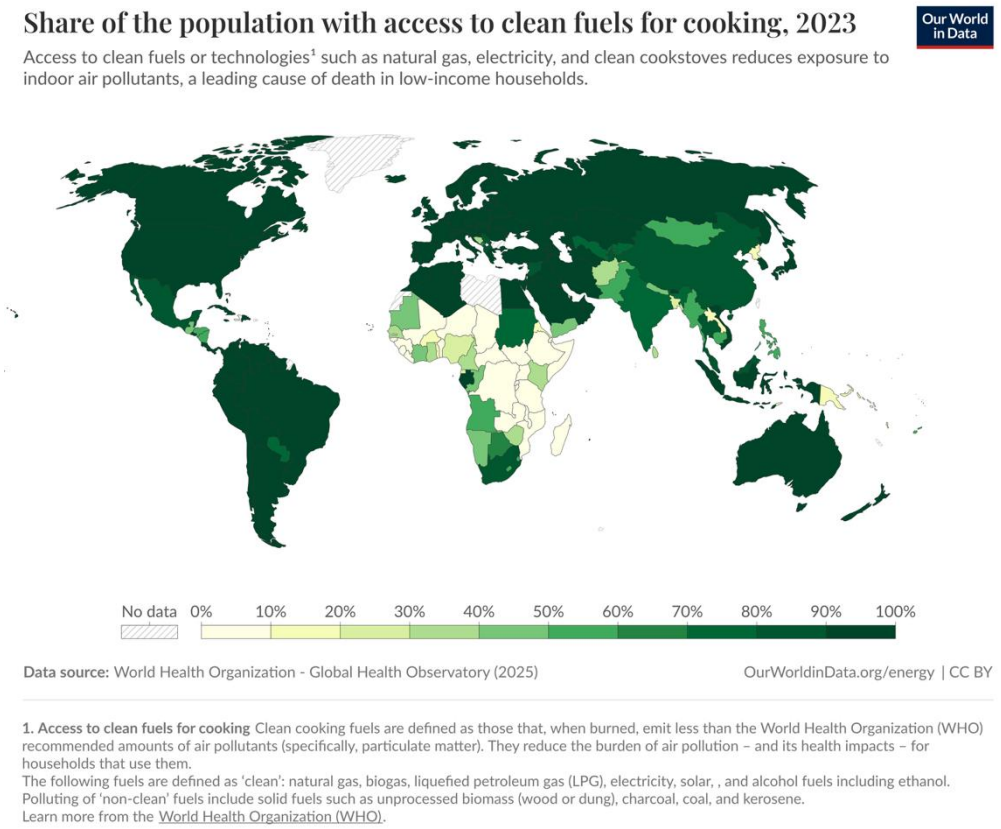

¿Qué tipos de preguntas puede responder la ciencia de datos?

Predictivo

¿Qué va a pasar?

¿Cuánto se calentará el planeta para 2100 bajo diferentes escenarios de política climática?

regresión, modelos de machine learning

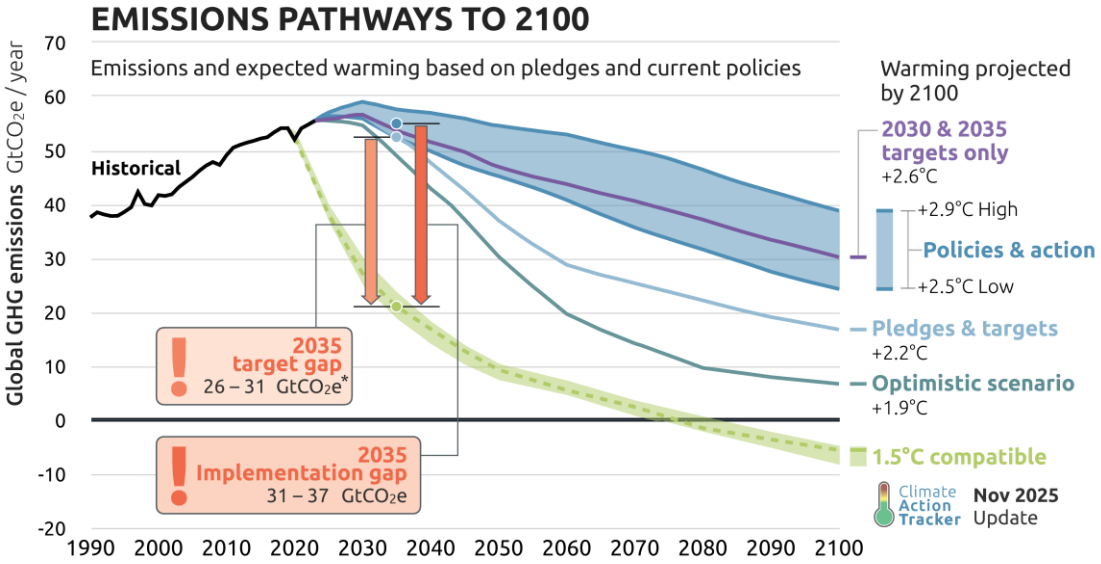

¿Qué tipos de preguntas puede responder la ciencia de datos?

Causal

¿Por qué ocurre
y qué pasa si…?

¿El programa Oportunidades redujo la pobreza y aumentó la escolaridad en México?

experimentos, diferencia en diferencias, RCTs

GiveWell

Program	CCT or UCT?	Conditions	% of PCE[3]	Key Findings
Oportunidades (formerly PROGRESA) (1997-), Mexico[4]	CCT	Health: checkups for all in household, lectures for 15+; Education: 80% attendance, complete middle school, compete grade 12 before 22.[5]	20[6]	10-20% increase in food consumption (more); 6% increase in long-term consumption (more)
Programa de Asignacion Familiar (PRAF) (1998-), Honduras[7]	CCT	Health visits and 85% school enrollment[8]	9[9]	N/A (all outcomes measured were conditioned outcomes)
Red De Proteccion Social (RPS) (2000-), Nicaragua[10]	CCT	Health: workshops, regular health care visits, up-to-date vaccinations, adequate weight gain; Education: enrollment, 85% attendance, grade promotion.[11]	27[12]	~15% increase in household expenditures; ~25% increase in food expenditures (more)
Atencion a Crisis (2005), Nicaragua[13]	CCT	Education: enrollment, 85% attendance; occupational training course; business grant plan.[14]	18[15]	~30% higher food consumption; more use of health services; improved self-reported health but unimproved on anthropometric measures (more)
Bono de Desarrollo Humano (2003-), Equador[16]	CCT but not monitored	No monitoring. Without being monitored: Health check-ups (0-5), Education: enrollment, 90% attendance.[17]	10[18]	Mixed impact on school enrollment, child labor and cognitive development (more)
Programa Apoyo Alimentario, Mexico[19]	CCT but not monitored	No monitored conditions[20]	11.5[21]	Slight improvements in weight for in-kind transfers (not for cash); slight decrease in self-reported sickness for both (more)
Zomba Cash Transfer Program, Malawi (2008-)[22]	Both	Unconditional group and conditional group (80% or better school attendance)[23]	15[24]	Improved school attendance & performance (more for conditional transfers); reduced psychological distress during but not after transfer period (more)

Tipos de preguntas en ciencia de datos

Descriptivo

¿Qué está pasando? ¿Cuánto? ¿Dónde?

No implica causa ni predicción

Predictivo

¿Qué va a pasar? ¿Quién tiene más riesgo?

Correlaciones útiles, sin necesidad de causalidad

F MPCEVÕ

¿Qué causó que pasara? ¿Qué cambiaría si intervenimos?

La pregunta más difícil — y la más importante

ĜÕÑÖ ŐŒÕÈMNMŌÑŎŌŎ ÑŒŃŎŌMØ

Descriptivo

¿Cuántos estudiantes abandonaron la secundaria en 2022 por estado?

Predictivo

¿Qué características en 1er año predicen que un estudiante va a abandonar?

Causal

¿El programa de becas redujo el abandono escolar?

¿Qué tipo de pregunta quieres hacer tú — descriptiva, predictiva o causal?

De la pregunta al modelo

Un mapa para el semestre — hoy solo lo plantamos, cada semana lo vamos a completar

1	**Pregunta descriptiva** *¿Quién emite más CO_2? ¿Cómo ha cambiado?*	→	**[illegible]**	*Semanas 3–7*
2	**Predecir algo continuo (Y numérica)** *¿Cuánto CO_2 emitirá un país según su PIB?*	→	**Regresión lineal**	*Semana 8*
3	**Predecir una categoría (Y sí/no, A/B/C)** *¿Este país está reduciendo emisiones o no?*	→	**Clasificación**	*Semana 9*
4	**[illegible]** *¿Qué tipos de países existen por perfil energético?*	→	**Clustering / ML no supervisado**	*Semana 10*
5	**Explicar una causa o evaluar una política** *¿El impuesto al carbono redujo las emisiones?*	→	**[illegible]**	*Semana 11*

Correlación ≠ Causalidad — distinción crítica en política

La trampa de la correlación

Ejemplo: los países que consumen más chocolate tienen más ganadores del Premio Nobel.

¿Deberíamos subsidiar el consumo de chocolate?

Por supuesto que no. Ambas están correlacionadas con la riqueza y acceso a la educación, no entre sí.

En política pública, confundir correlación con causalidad puede resultar en intervenciones que no funcionan — o que hacen daño.

El estándar de oro: causalidad

- Experimentos aleatorizados (RCTs)
- Diferencia en diferencias (DiD)
- Variables instrumentales (IV)
- Regresión discontinua (RD)

En este curso aprenderemos a hacer las preguntas correctas antes de elegir el método.

La ciencia de datos no reemplaza al pensamiento crítico — lo amplifica.

Los datos no son neutrales — riesgos y consideraciones éticas

Dedicaremos la Semana 2 completa a ética. Por ahora, tres alertas fundamentales:

01

Sesgo en los datos

Los datos reflejan el mundo como fue registrado, no como es. Si los sistemas históricos discriminaron, los datos también discriminan.

Ej: Algoritmos de crédito que discriminan por código postal

02

Información faltante

Los datos que no existen son invisibles. Las poblaciones más marginadas suelen estar sub-representadas en registros oficiales.

Ej: Encuestas que no llegan a comunidades indígenas

03

Mala interpretación

Correlación no es causalidad. Una relación estadística no implica que un factor cause al otro — ni que una política vaya a funcionar.

Ej: Países con más chocolate tienen más Nobel

Los datos no son neutrales — riesgos y consideraciones éticas

Los datos no son neutros. Reflejan las decisiones de quienes los recolectaron, los sesgos del sistema que los genera, y los intereses de quienes los interpretan.

Eso no significa que no sirvan — significa que hay que usarlos con cuidado.

Herramientas del curso

Todo el trabajo práctico será en Python — el lenguaje más usado en ciencia de datos aplicada.

Python	Lenguaje base	Legible, versátil, enorme comunidad
Jupyter	Entorno interactivo	Código + narrativa + visualizaciones juntos
pandas	Manipulación de datos	El equivalente de Excel, pero programable
seaborn / matplotlib	Visualización	Gráficas listas para reportes
scikit-learn	Machine learning	Regresión, clasificación, clustering

No es necesario ser experto en Python. Aprenderemos lo necesario a lo largo del curso.

Estructura del curso — TC4036

Semanas 1–2

Introducción, datos públicos y ética

Semanas 3–4

Recolección y limpieza de datos

Semanas 5–6

Visualización de datos para análisis de política

Semanas 7–8

Análisis estadístico y regresión

Semanas 9–10

Machine learning para predicción de políticas

Semanas 11–12

Evaluación de políticas y proyecto final

Evaluación del curso

40%

Proyecto Final

Ensayo aplicado: análisis de política pública con datos reales.
Entrega semana 12 + presentación de 10+2 minutos.

30%

Avances del proyecto

3 entregas progresivas en semanas 4, 7 y 10.
Sirven como checkpoints para el proyecto final.

20%

Examen Final

Conceptos de todo el curso.
En aula, escrito.

10%

Participación

Artículos, discusión en clase, ejercicios del lab.

El proyecto final

Elige un problema de política

Cualquier área — clima, salud, pobreza, educación, seguridad, migración. Lo que te importe más.

Usa datos reales

CONEVAL, INEGI, Banco Mundial, Our World in Data, SEMARNAT — todos abiertos y gratuitos.

Analiza y recomienda

No es solo describir datos. Debes responder: ¿qué debería hacer el gobierno con esto?

Entregas

Semana 4
Propuesta de tema

Semana 7
Avance: datos limpios + EDA

Semana 10
Avance: análisis estadístico

Semana 12
Entrega final + presentación

¿Qué problema de política les gustaría analizar? Empiecen a pensarlo esta semana.

Inspiración para tu proyecto

El tema es libre — lo importante es tener una pregunta de política y datos con qué responderla.

Clima y energía

Transición energética, emisiones por país, políticas de carbono

Pobreza y bienestar

Programas sociales, transferencias, CONEVAL, pobreza extrema

Agua y medio ambiente

Acceso a agua potable, calidad, deforestación municipal

Seguridad

Homicidios municipales, prevención del delito, desplazamiento

Salud pública

Mortalidad materna, acceso a servicios, cobertura de vacunación

Alimentación

Seguridad alimentaria, subsidios agrícolas, precios de canasta

Educación

Rezago escolar, brechas de género, abandono en secundaria

Migración

Factores de expulsión, remesas y pobreza, integración regional

Lab para trabajar con datos

- Cargar datos reales del Banco Mundial (~100 países)
- Explorar GDP, esperanza de vida y regiones del mundo
- Responder tu primera pregunta de política con código

Lectura para la próxima semana

Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019).
"Dissecting racial bias in an algorithm used to manage the health of populations." *Science*, 366(6464), 447–453.